4-2. Agent 모델

목차

Part1. Mastering AI Agent

인공지능의 새로운 지평

- 인공지능 분야는 빠르게 발전하고 있으며, AI 에이전트가 핵심적인 혁신 기술로 부상하면서 인간과 컴퓨터의 상호작용 및 자동화 영역을 새롭게 정의할 것으로 기대

Perception AI (지각 AI)

- 특화된 분야에서 해석 및 분석
- 현대 기게 학습의 기반

Generatve AI (생성형 AI)

- 콘텐츠 제작(텍스트, 이미지 등)
- “The Creative Powerhouse”
- 아직까지는 수동적인 AI

Agentic AI(에이전트형 AI)

- 능동적인 작업 수행
- “자율형 문제해결 시스템”
- 스스로 외부 도구를 호출하며 문제를 해결

Physical AI(물리적 AI)

- 현실 세계에서 작동
- AI 시스템이 물리적 실체를 얻음
- 실체 몸이 있어 물리적 상호작용 할 것이라 기대

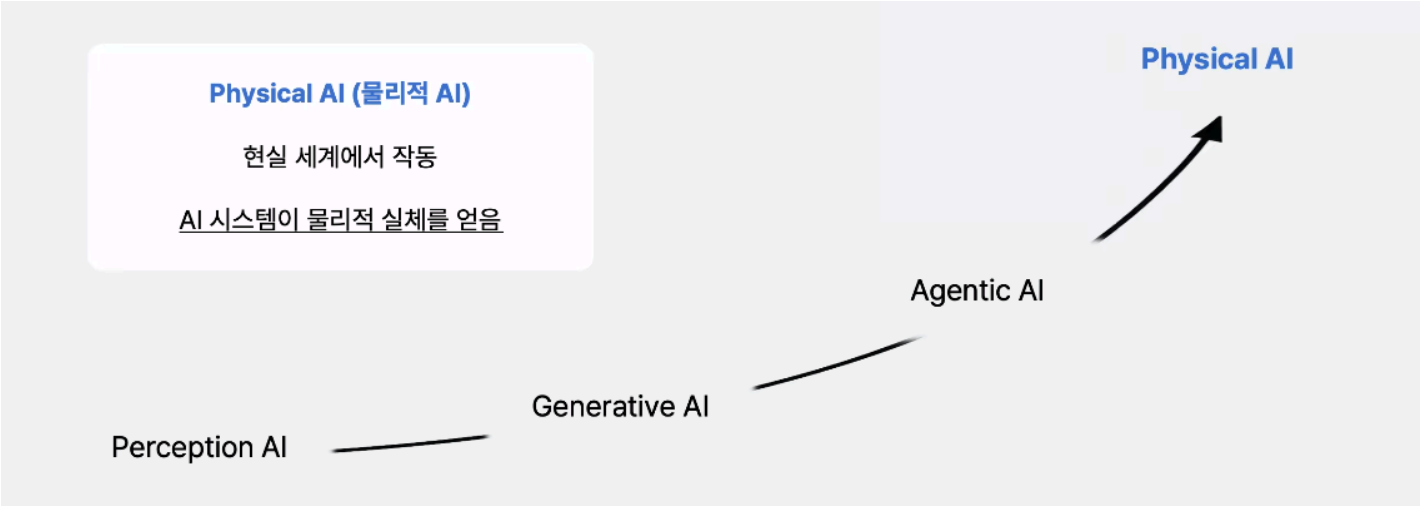

생성형 AI에서 에이전트형 AI로

- 생성형 AI (ex, LLM, VLM, MLLM) 가 크게 발전하는 가운데, 더욱 복잡한 환경에서 이러한 모델들을 적용하려는 시도가 증가하고 있음
- AI가 스스로 논문의 주제를 정하고 실험하고 논문 작성까지 진행 → 실제 학회 제출된 AI의 논문

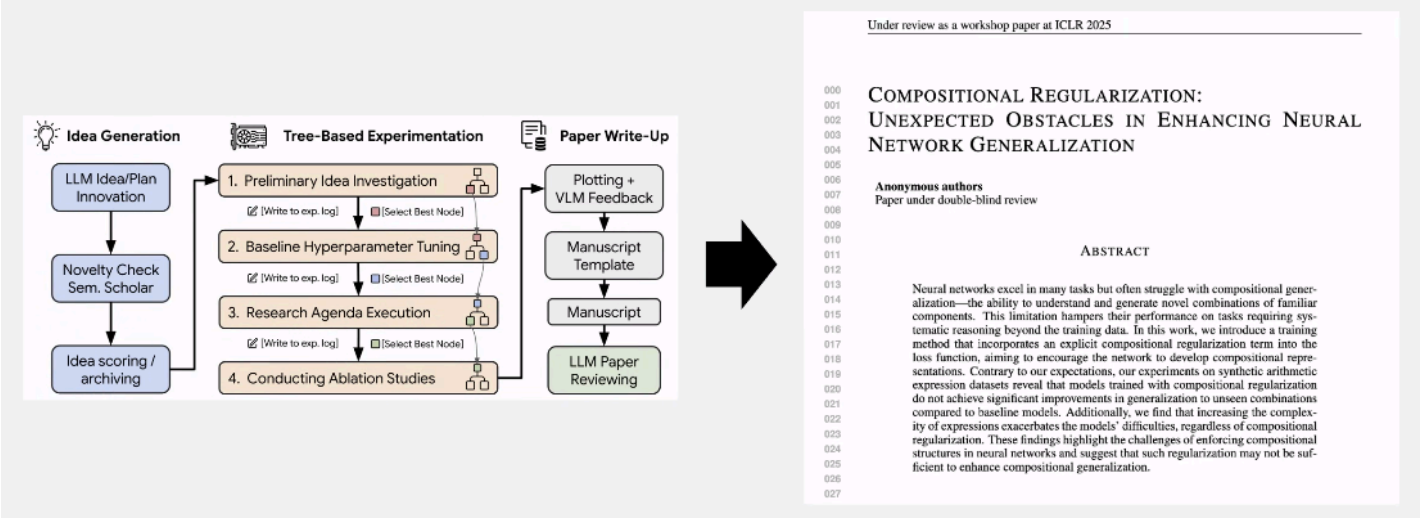

지금은 AI 에이전트의 시대

- ChatGPT Agent (25.07.17)
- Gemini CLI (25.6.25)
- Model Context Protocol (24.11.26)
- MS Copilot Studio (24.11.19)
- Bedrock Agents (24.5.2)

에이전트란?

- 에이전트 : 다른 사람 또는 단체를 대신하여 행동하는 개인 또는 단체
- 에이전트는 특정 작업을 수행하고, 결정을 내리며, 합의를 도출하는 것을 목표로 함
  - ex) 세탁기 : 세탁이 필요한 상태를 인식(환경인식) → 세탁 순서 결정(의사 결정 과정) → 세탁 진행

- **작업:** 옷을 세탁하기
- **의사 결정:** 사전에 정의된 세척 순서
- **상황 인식:** 세탁이 필요한 상태

AI 에이전트?

- AI 에이전트 : AI를 사용하여 사용자를 대신해 목표를 추구하고 작업을 수행하는 소프트웨어 시스템

    - 스스로 상황을 인식하고 가장 적절한 방법을 찾아서 수행

AI vs AI 에이전트

- 우리는 실제로 AI와 AI 에이전트를 명확하게 구별하지 않음
- 특히 현대 대규모 언어모델 (LLM) 관점에서 AI를 바라 볼 때, 그 경계는 더욱 모호함

AI 에이전트의 주요 특성

- 자율성 : 인간의 개입 없이 계획하고, 실행하고, 결정하여, 문제를 자율적으로 해결할 수 있음
- 인식 : 행동하기 전에 외부 데이터를 감지하여 환경을 인식하고 해석할 수 있음
- 기억 : AI 에이전트는 기억에 따라 상황을 처리하고 점점 더 정교한 도움을 제공할 수 있음
- 추론(계획) : AI 에이전트는 목표를 여러 개의 작은 작업들로 나누고, 실행하기 전에 합리적인 행동 계획을 구축할 수 있음
- 학습(적용) : 시간이 지남에 따라 피드백 및 출력을 학습하여 성능을 향상시키고 개인화함
- 동작(도구) : 기능 호출을 통해 외부 도구를 사용하여 작업을 처음부터 끝까지 완료할 수 있습니다.

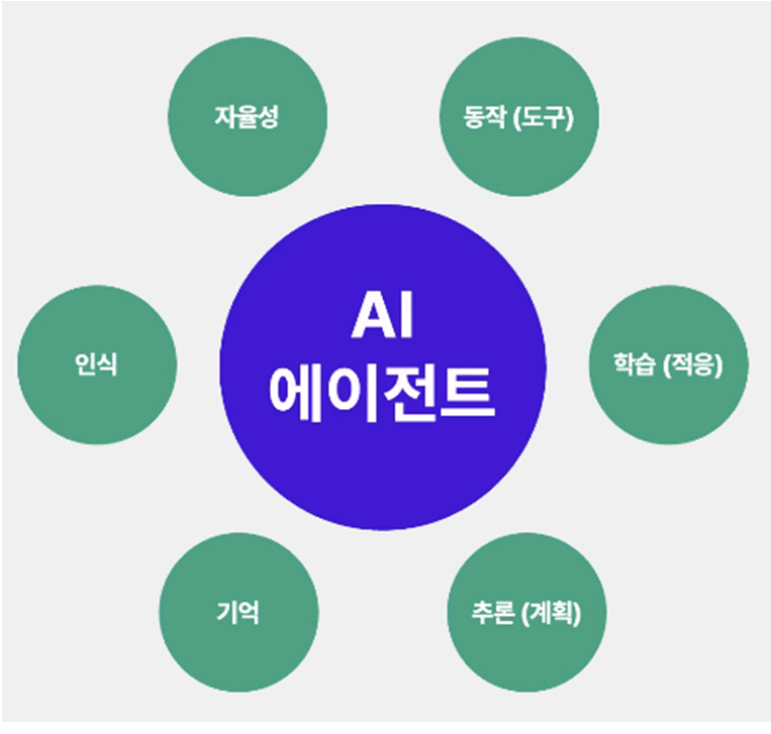

AI Agent의 도전 과제

- 학술 연구 영역
    - 다중 에이전트 협업 시스템
    - 메모리와 컨텍스트 관리
    - 작업 관리
    - 확장성과 성능
- 실무 응용 영역
    - 보안 및 개인정보 문제
    - 자율성의 고위험 요소
    - 추론 비용과 실시간 협업
    - 윤리적 문제와 편향성에 대한 우려

Part2. Multi-Agent System

대규모 언어 모델(LLM)

- 대규모 언어 모델의 최신 성과

    - 창의적 글쓰기, 논리적 사고, 판단 능력
    - 인간 수준에 필적하는 성능
- 개별 LLM의 본질적 한계
    - 환각 현상 : 부정확하거나 조작된 정보 생성
    - 자기회귀적 성격 : 천천히 생각하거나 신중한 추론을 할 수 없음
    - 스케일링 법칙 : 모델 크기 증가에 따른 성능 향상 둔화

왜 다중 에이전트 시스템이 필요한가?

- 집단 지성
    - 지능형 에이전트들이 팀을 이루어 협력하고 지식을 나누며, 함께 문제를 해결하는 능력에 초점을 맞춤(수평적 확장)
    - 인간 사회는 일상 업무부터 과학 연구까지 팀워크와 역할 분담을 통해 공통 목표를 달성하는 데 탁월
    - 다중 에이전트 시스템도 이와 같은 원리를 적용하여, AI 에이전트들이 서로의 장점과 시각을 결합해 효율적으로 협업하도록 함
      → 개별 에이전트들의 능력의 총합을 뛰어넘는 진정한 집단 지성을 실현하고자 함

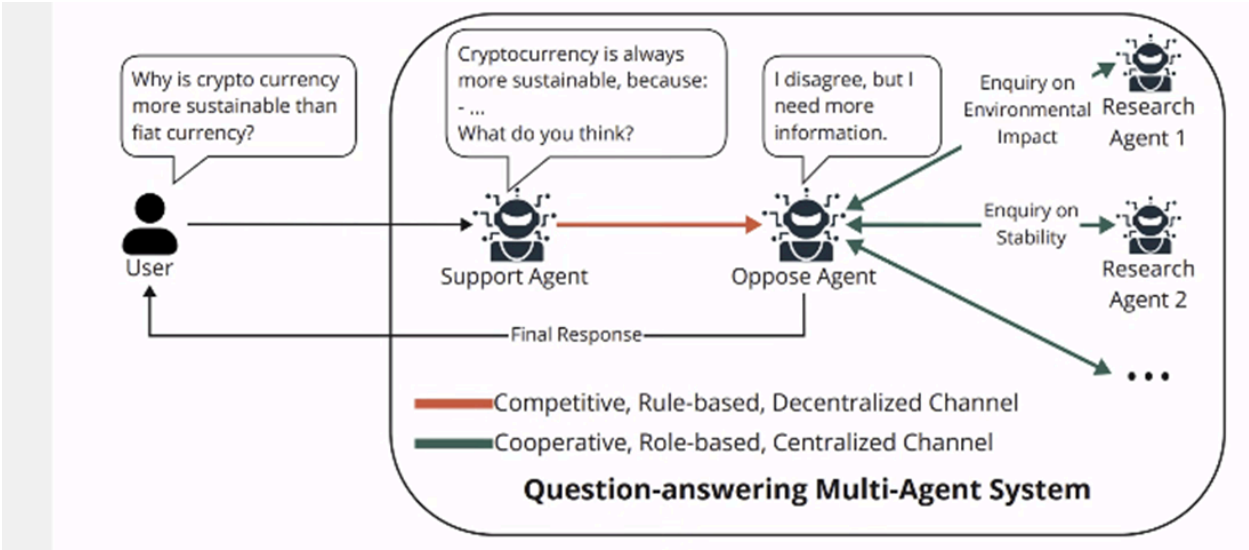

LLM 기반 다중 에이전트 협업 시스템의 질의응답 활용 예시

LLM 기반 다중 에이전트 시스템의 협업 요소와 메커니즘

- 협업 유형, 전략, 소통 및 조직 구조

시사점 및 남은 문제들

- 집단적 추론, 의사결정 등 다중 에이전트 시스템의 발전과정에서 아직 해결해야 할 문제들이 존재

다중 에이전트 시스템의 주요 구성 요소

- 에이전트
    - 역할 , 능력, 행동, 지식 모델을 가진 핵심 행위자들
- 환경
    - 에이전트가 존재하고 인식 및 행동할 수 있는 외부 세계
- 상호 작용
    - 표준화된 통신 언어를 사용한 에이전트 간 소통
- 조직
    - 에이전트들은 계층 구조로 관리되거나 자발적인 행동으로 조직

협업 유형

- 협력 관계 (Cooperation): 학술 글쓰기 지원 시스템
- 경쟁 관계 (Competition): 법정 시뮬레이션
- 협력적 경쟁 관계 (Coopetition) : 정책 결정 시스템

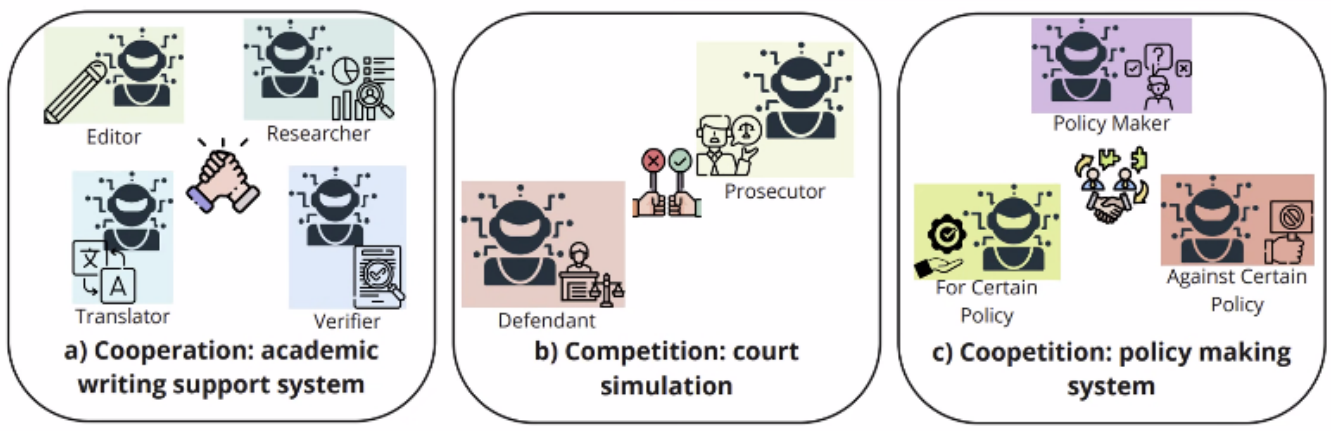

협력 관계

- 에이전트들은 각자의 개별 목표를 공동의 집단 목표와 일치시켜, 상호 이익이 되는 결과를 달성하기 위해 협력
- 에이전트들은 각자의 전문 분야 내에서 특정 세부 작업에 집중하도록 활용 할 수도 있음
- 에이전트 간 빈번한 통신과 다중 협업 채널은 계산 비용과 복잡성 증가를 초래할 수 있음
- 개별 에이전트의 신뢰성과 성능에 크게 좌우되어, 한 개 이상의 에이전트의 오류가 시스템 전체에 부정적 영향을 미칠 수 있음 (e.g. 무한 대화 루프, 환각 현상 증폭)

경쟁 관계

- 에이전트들은 각자의 개별 목표를 우선시하며, 이는 다른 에이전트들의 목표와 충돌하거나 대립할 수 있는 경쟁 요소를 도입
- 에이전트들이 고도의 추론 능력과 더 창의적인 문제해결 방법을 개발하도록 촉진
- 각 에이전트의 능력의 한계를 시험함으로써 시스템의 적응성을 강화
- 경쟁적 협업 경로는 강력한 프롬프트를 가진 단일 에이전트에 의해 따라잡힐 수 있음
- 끝나지 않는 논쟁

협력과 경쟁의 조합

협력과 경쟁의 전략적 조합

- 에이전트들이 공동 목표 달성을 위해 특정 작업에서는 협력하면서 동시에 다른 작업에서는 경쟁할 수 있도록함

전문가 혼합 모델 (Mixture-of-Experts)

- 다양한 전문가 모델들이 최종 결과물에 기여하려고 경쟁하고, 게이트 시스템이 각 입력에 맞는 최적의 전문가를 골라냄
- 전문가들 사이의 협력 및 경쟁적 관계는 모델 학습 과정에서 먼저 형성되며, 이때 각자가 데이터의 서로 다른 측면에 대해 전문화하도록 훈련

방법론 : 협력 전략

1. 규칙 기반 프로토콜

사전에 정의된 규칙

- 에이전트 간 상호 작용은 미리 정의된 규칙에 의해 엄격히 통제

인간의 협력 방식 모방

- 동료 검토에서 영감을 받은 협업 메커니즘을 사전 정의된 규칙을 사용하여 에이전트들이 서로의 출력을 비판하고, 수정하며, 개선할 수 있도록 함
- 규칙 기반 전략은 시스템 동작과 특정 규칙을 쉽게 연결할 수 있으므로 구현과 디버깅을 용이하게 함

- 합의 도출, 경로 찾기와 같이 절차가 명확히 정의되고 변동성이 적은 작업에 특히 효율적

2. 역할 기반 프로토콜

사전에 정의된 역할

- 세분화된 목표 하에서 각 에이전트가 고유한 역할 분담이나 업무 분할을 통해 작동하도록 함

주로 도메인 지식에 기반

- 각 에이전트에 특정 책임을 할당하여 인간과 유사한 협업을 시뮬레이션 하고, 역할 준수를 통해 일치성 강화
- 각 에이전트의 역할은 전문가 수준의 지식으로 정의되어, 에이전트는 서로의 결과를 검증할 수 있는 전문가의 역할을 할 수 있음
- 개별 모듈의 재활용 가능성

방법론 : 커뮤니케이션 구조

중앙집중형 구조

- 참여자-서비스 제공자 구조
  - 서비스 에이전트는 시스템 안에서 참여자들 사이의 소통이나 협력을 관리, 제어, 조율하는 역할을 담당

중앙 에이전트

- LLM-블렌더는 한 라운드에서 서로 다른 LLM들을 호출하고, 두 개씩 비교하여 순위를 책정한 후, 최상위 응답들을 결합
- 판사 에이전트(토론), 최종 의사결정을 위한 의사(MDT 프로세스)

탈중앙화 구조 : 에이전트에 대한 통제 및 의사결정 분산

- 각 에이전트는 에이전트와의 제한적인 통신과 일부의 정보를 바탕으로 작동하므로, 상호작용과 의사결정을 위한 정교한 알고리즘이 필요
- 에이전트들이 분산형으로 서로 직접 소통하는 방식으로 작동
- 일부 에이전트가 실패해도 시스템이 계속 기능할 수 있음
- 높은 확장성을 제공하며, 에이전트들이 자율적으로 작동하고 시스템 변화에 적응할 수 있음

다중 에이전트 시스템에 대한 우려의 시사점

- 확장성 고려사항
  - 성능 저하 없이 더 큰 에이전트 네트워크를 처리하기 위해서는 확장 가능한 아키텍쳐와 알고리즘 구현이 필수적
- 최적 협업 전략
  - 효과적인 협업을 위해서는 작업 요구사항에 맞는 최적의 협업 전략을 선택하는 것이 중요
- 적응 가능한 역할 및 협업 경로 할당
  - 적응가능성은 시스템이 변화하는 환경과 목표에 효과적으로 대응할 수 있도록 함

Part3. Memory & Tool in Multi Agent System

패러다임의 전환 : 언어 모델에서 에이전트 시스템으로

- AI는 전통적인 대규모 언어 모델(LLM)에서 독립적 사고와 행동을 할 수 있는 자율적인 AI 에이전트의 새로운 패러다임으로 발전하고 있음
- 고정된 매개변수 메모리에 제한을 받는 수동적인 LLM과 달리, AI 에이전트는 실시간 정보에 접근하고, 외부 도구를 활용하며, 물리적 또는 디지털 세계와 상호작용하고, 정적인 훈련 데이터를 넘어서서 적응할 수 있음
- AI 에이전트는 환경을 인지하고, 계획을 수립하며, 특정 목표 달성을 위해 구체적인 행동을 실행할 수 있는 능동적 개체

LLM이 혼자 모든 작업을 할 수 있을까에 대한 의문

여러 도구를 통해 LLM을 똑똑하게 도와주자.

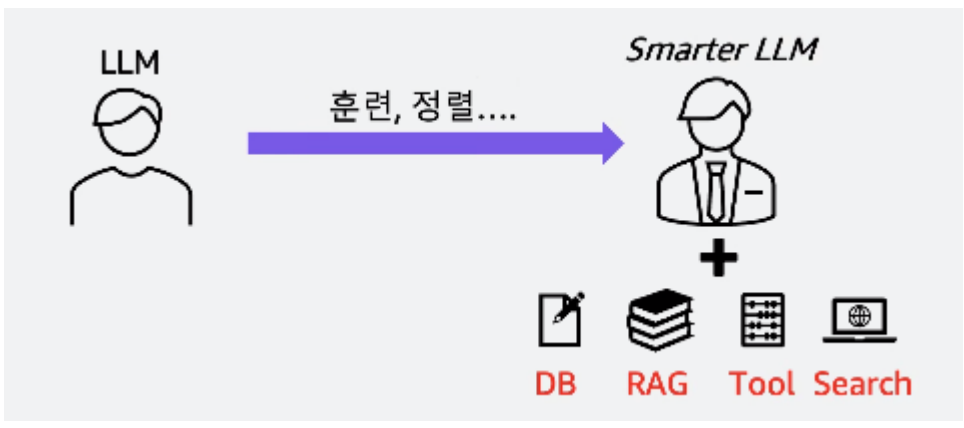

기억/지식 - 학습 데이터 범위를 넘어서는 광범위하고 변화하는 외부 정보를 활용 및 분석하는 능력

- 핵심 질문 : 에이전트가 최신 정보를 어떻게 습득하는 가? (RAG, 메모리)

행동/능동성 - 외부 환경과 소통하고 변화를 일으키는 능력

- 핵심 질문 : 에이전트가 구체적인 업무를 어떻게 완수하는가? (도구 호출)

학습/적응 - 축적된 경험을 바탕으로 기억과 행동 방식을 발전시키는 능력

- 핵심 질문 : 에이전트들이, 특히 공동 작업 시, 어떻게 지능을 향상 시키는 가? (멀티 에이전트 학습)

메모리 & 도구

LLM 내장 매개변수 메모리의 한계

- 낡은 지식 - 학습 시점에 지식이 고정되어 최신 정보를 반영할 수 없음
- 환각 현상 - 그럴듯 하지만 잘못된 내용을 생성하는 경향
- 사적 정보 접근 불가 - 기업 내부 정보나 개인화된 정보를 검색할 수 없음

→ 이런 제약들로 인해 실제 핵심 업무에서 LLM을 믿고 사용하기 어려움

검색증강 생성(RAG)

- 핵심 아이디어 - LLM이 답변을 생성하기 전에 신뢰할 수 있는 외부 소스 (ex : 데이터베이스, 최신 웹 문서) 에서 관련 정보를 검색하고, 해당 정보를 바탕으로 응답을 구성
- 장점 - LLM의 자연스러운 표현력과 외부 지식의 정확성, 시의성, 검증 가능성을 결합하여 더욱 신뢰할 수 있고 근거가 확실한

일반적 검색증강생성(RAG)의 한계점

- 단순한 RAG 구조는 외부 지식 소스를 하나만 사용하지만, 때로는 두 개의 외부 지식 소스가 필요하거나, 웹 검색과 같은 외부 툴과 API가 요구되는 경우도 존재
- 일회성 방식으로 정보를 딱 한번만 가져오기 때문에 가져온 정보의 품질에 대한 검토나 확인 과정이 없음

- 기존의 선형 RAG 방식은 간단한 질의응답에는 효과적이지만, 상태 정보를 저장하지 않는다는 특성 때문에 여러 단계의 추론이나 복합적인 탐구에는 한계가 존재
    - “기억하기 못하는 검색 엔진”과 같아, 맥락을 유지하거나 제대로 된 조사 작업을 수행할 수 없음

    → RAG + 에이전트 = 에이전트형 RAG

에이전트형 RAG란?

- AI 에이전트가 RAG 파이프라인을 향상시켜, 각 단계들을 조율하고 단순한 검색/생성을 넘어서는 역할을 하도록 함
- 주로 벡터 검색, 웹 검색, 계산기, API 등의 도구를 사용하는 방식으로 정보 검색에 적용
- 에이전트가 할 수 있는 일 : 검색 여부 결정, 도구 선택, 쿼리 생성, 결과 평가/재검색

AI 에이전트의 주요 구성 요소

- LLM(특정 역할과 작업을 담당)
- 메모리(단기 기억 및 장기 기억)
- 계획(ex: 자기 성찰, 자기 비판, 쿼리 분배 등)
- 도구 (ex: 계산기, 웹 검색 등)

AI 시스템 속의 에이전트

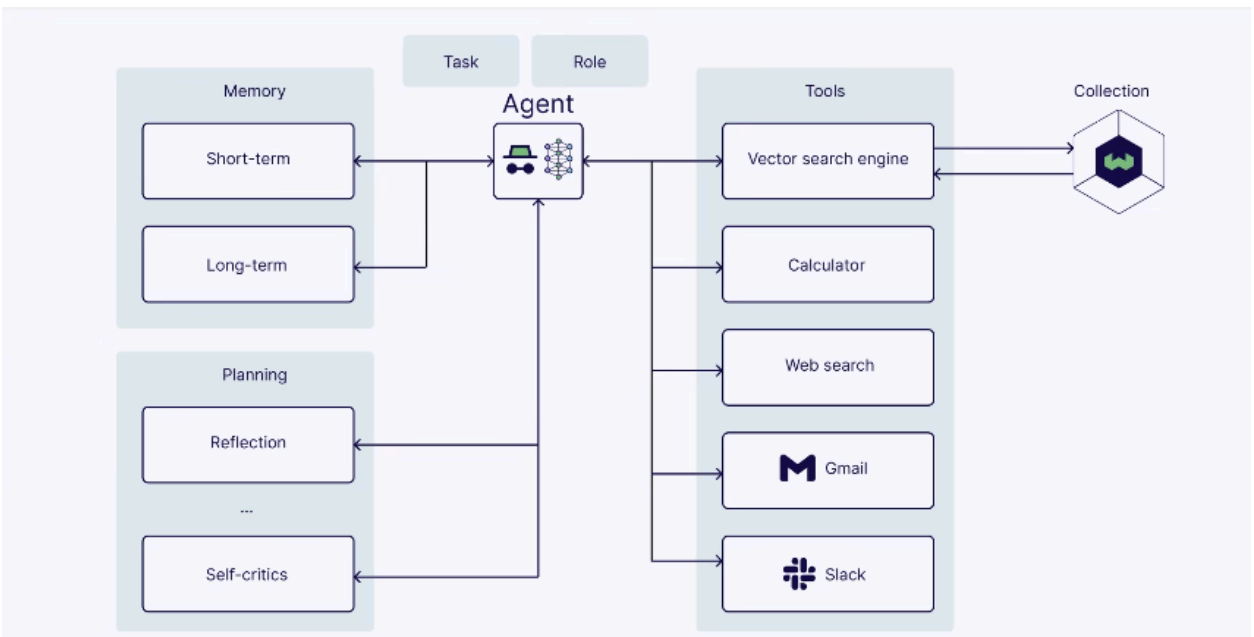

단일 에이전트형 RAG(Router)

멀티 에이전트형 RAG 시스템

멀티 에이전트 시스템을 위한 훈련 방법

딜레마 : 언제, 무엇을, 어떻게?

- 언제 : 매개변수 기반지식으로 답할지 도구를 호출할지 결정 (trade-off : 비용/지연시간 vs 정확성)
- 무엇을 : 적절한 도구 선택 (ex: 계산기, 웹 검색, 데이터베이스 쿼리)
- 어떻게 : 선택한 도구의 API에 올바른 인수 전달

→ 해석 : 반환된 결과 또는 오류를 분석하고 다음 행동을 결정

이러한 의사결정 단계들이 모려서 에이전트의 행동 정책(policy)를 형성하며, 이는 강화학습을 통해 효과적으로 학습될 수 있음

Toolformer : 언어모델이 스스로 도구 사용법을 학습

- 목표 : 생성 과정에서 언어모델이 언제, 어떻게 외부 도구를 사용 할 지 스스로 결정할 수 있도록 함

- 핵심 아이디어 : 자기 지도 학습 - 모델이 인간의 주석 없이 자신이 생성한 API 호출 예시로부터 학습
- 학습 방법 :
  - 소규모 API 호출 데모 세트로 시작
  - 언어 모델이 새로운 맥락에 API 호출 삽입
  - 호출 실행, 응답 검색, 유용성에 따른 필터링, 언어 모델 미세조정

Gorilla : LLM을 대규모 API와 연결

- 목표 : LLM이 대규모 실제 API 세트를 안정적으로 호출하고 사용할 수 있도록 하여 정확도와 근거, 기능을 향상
- 접근 방식 :
  - APIBench 데이터셋으로 LLAMA 및 GPT와 같은 모델 미세조정
    - APIBench : API 문서의 대규모 데이터 세트, 사용법 예제 및 도구 호출 패턴
  - API 호출 생성 전 관련 API 문서를 불러오는 검색 증강 미세조정(RAFT) 사용
- 주요 기능 :
  - 정확한 서식으로 수십만 개의 API를 처리
  - 문서 검색 + 지도 미세 조정(SFT)를 통해 “환각” API 호출 감소

ReTool : LLM의 전략적 도구 사용을 위한 강화 학습

- 목표 : 외부 도구를 사용하는 시점, 도구 선택, 방법을 학습시켜 복잡하고 계산 집약적인 작업에서의 LLM추론 능력을 향상
- 접근 방식 - 2단계 훈련 방식 :
  - 선별된 코드로 증강된 추론 흔적을 활용한 콜드 스타트 SFT
  - PPO를 통한 강화학습 + 실시간 코드 실행 및 피드백
- 주요 특징 - 결과 기반 보상을 통해 도구 호출 타이밍, 도구 선택, 코드 개선, 자기 수정을 학습

Search-R1 : LLM을 사용한 더 나은 웹검색을 위한 강화 학습

- 목표 : LLM 에이전트가 자율적으로 다단계 웹 검색을 수행하여 답변의 정확성과 관련도를 개선하도록 함
- 접근 :
  - 검색 증강 LLM 에이전트를 훈련시켜, 언제 어떻게 검색할지를 결정하고, 질의를 구성하며, 관련 결과를 선택하고, 이를 최종 답변에 통합하도록 함
  - 사람에 의한 피드백에 대한 선호를 활용한 온라인 강화학습으로 검색 전략을 개선
  - 에이전트는 도구 사용(검색 vs 검색안함), 질의 구성, 반복 개선에 대한 정책 학습
- 강화학습 기법 : 그룹 상대 정책 최적화(GRPO)를 기반
  - GRPO : PPO에서 발전된 강화학습 방법으로 각 업데이트에서 여러 실행 결과물을 비교하여 더 나은 검색 기반 결과에 보상을 제공

MCP(모델 컨텍스트 프로토콜)

정의 : MCP는 AI 모델이 외부 도구, 리소스 , 환경과 원활하게 상호작용할 수 있도록 하는 표준화된 인터페이스로, “AI 기능의 USB-C” 와 같은 역할

왜 중요한가 :

- MCP가 없다면 M개의 AI 애플리케이션을 N개의 도구에 연결하기 위해 MxN 개의 개별적인 통합이 필요
- MCP는 연결을 표준화하여 이를 M+N으로 단순화함

아키텍처 개요

- 호스트 - AI 애플리케이션 환경 (ex, 채팅앱, IDE)
- 클라이언트 - 호스트와 MCP 서버 간 통신 처리
- 서버 - 표준 형식으로 도구, 리소스, 프롬프트 제공

핵심 기능 :

- 도구 - 실행 가능한 작업 (ex, 쿼리실행, 날씨정보 가져오기)
- 리소스 - 읽기 전용 데이터 소스 (ex, 문서, 데이터베이스)
- 프롬프트 - AI 행동을 지도하는 사전 정의된 템플릿 또는 워크 플로

효과 :

- 연결 작업의 복잡함 해소
- 도구와 자료의 재활용성 증대
- 여러 도구를 활용하는 유연한 AI 에이전트 개발 촉진

Agent2Agent 프로토콜

목표 :

- 여러 AI 에이전트가 내부 메모리, 사고, 도구를 직접 공유하지 않고, 맥락, 작업 업데이트, 지시사항, 데이터만 교환하여 협업할 수 있도록 함

MCP와의 관계

- MCP - 에이전트를 외부 도구에 연결
- A2A - 에이전트 간 협업 지원

핵심 개념 :

- 에이전트 서버 : 개별 에이전트를 호스팅
- 클라이언트 에이전트 : 여러 에이전트 서버로 연결
- 라우터 : 쿼리를 적절한 에이전트로 전달

Part4. Reasoning and Planning in AI Agent

추론 능력이 있는 대규모 언어 모델

- 대규모 언어 모델은 논리 퍼즐, 수학적 문제, 코딩과 같은 복잡한 작업을 해결할 수 있음

→ 이러한 질문에 답하기 위해 LLM은 단계별 사고 과정, 즉 “추론”을 수행 할 수 있어야 함

대규모 언어 모델의 추론 유도

프롬프트 만으로도 추론 능력을 이끌어 낼 수 있음

- Few-shot prompting(Chain-of-Thought Prompting)
  - “Step by step”

자기 일관성 : 다양한 추론 과정을 생성하고 그 중 가장 일관성 있는 답변을 고르는 디코딩 방식

대규모 언어 모델의 추론 능력 강화

- Tree of Thoughts : 너비 우선 탐색(BFS)또는 깊이우선탐색(DFS) 방식으로 다양한 생각으로 생성하고 평가

LLM의 에이전트의 Planning

- LLM은 여러 사고 단계를 생성할 수 있음. 즉 목표 달성을 위한 하위 목표들의 순서를 구성할 수 있음. 행동(실행) 명령을 통합하면 LLM이 결과를 되돌아보면서 도구를 사용하거나 행동 할 수 있음

ReAct : 추론만 하거나 행동만 하는 것이 아니라 '생각'과 '행동'을 함께 생성하는 방식

HuggingGPT : 계획 수립을 담당하는 LLM이 복잡한 작업을 나누어 각각의 전문 모델들에게 분배하는 시스템

LLM 에이전트의 Planning 능력 강화

- Reflection : LLM 에이전트가 생성한 텍스트와 행동에 대해 언어적 피드백을 제공하여 성능을 강화하는 시스템
- Plan-and-Act : 계획 에이전트는 거시적인 계획을 생성하고, 실행 에이전트는 해당 계획에 따라 하위 단계를 실행하는 시스템

추론 시간의 연산량 증대

- 추론 시에 컴퓨팅 자원을 더 많이 투입할 수록 LLM의 성능이 향상됨
- 이는 난이도가 낮은 작업에서 모델 매개 변수를 늘리는 것보다 더욱 효과적일 수 있음\
- 스케일링의 법칙도 적용됨

추론 모델

- 추론을 위한 추가 컴퓨팅 자원이 할당된 추론 모델이 등장하기 시작
  - o1 (OpenAI)
  - DeepSeek-R1
  - Gemini Series (thought)
  - Claude Series (ThinkingBlock)
  - GPT Series(reasoning summary)
  - Open-source Models

추론 모델 강화

- 정확성과 올바른 형식에 대해서만 보상을 제공함으로써 LLM이 chain-of-thought을 사용하는 방법을 학습하게 함

효율적인 추론

- 과도한 사고 현상
  - 더 긴 CoT 추론 과정은 실제로 성능을 향상시키지만, 장황하고 중복되는 출력으로 인해 계산 부담 크게 늘어나는 것은 여전히 문제
- 분류
  1. 모델 기반 접근
  2. 추론 결과 기반 접근
  3. 입력 프롬프틀 기반 접근

- 모델기반 접근 (가변 길이)
  - DeGRPO : 첫 번째로 생성된 토큰(제어토큰), <short>, <think> 으로 추론 길이를 제어하는 방식

- 추론 결과 기반 접근 (동적 추론)
  - InftyThink : 일부 추론 과정을 만들어내고, 지금까지의 생각을 요약하는 방식

- 입력 프롬프트 기반 접근(라우팅)
  - 쉬운 질문에는 연산량을 적게, 복잡한 질문에는 연산량을 많이 배정하는 방식

Part5. Domain-Specific AI Agent

끝